

Sprint 3 — MLP

Inteligência Artificial aplicada à Medicina do Estilo de Vida

Integrantes:

Edson Leonardo Pacheco Navia;

Eduardo Mazelli;

Lucas Masaki Nagahama;

Joseh Gabriel Trimboli Agra;

Pedro Henrique de Assunção Lima.

Repositório:

https://github.com/GiantMazelliWasHere/IA_MLP_Sprint-3

Objetivo

Utilizar uma MLP (Multilayer Perceptron) para resolver um problema dentro do projeto de Medicina do Estilo de Vida — classificar o nível de obesidade/saúde de um indivíduo a partir de dados de hábitos diários (alimentação, atividade física, hidratação, uso de tecnologia, consumo de álcool, fumo e meio de transporte). Esses hábitos correspondem diretamente aos 6 pilares da Medicina do Estilo de Vida: alimentação saudável, atividade física, sono, manejo do estresse, conexões sociais e evitar substâncias de risco.

1. Problema

Doenças crônicas não transmissíveis (DCNTs) — obesidade, diabetes, hipertensão e cardiopatias — são responsáveis por cerca de 70% das mortes no mundo, segundo a OMS. A Medicina do Estilo de Vida defende que esses quadros podem ser prevenidos e até revertidos pela mudança de hábitos. O desafio prático: como identificar precocemente o risco de um indivíduo com base apenas em seu estilo de vida, sem precisar de exames laboratoriais?

Solução proposta: treinar uma rede neural MLP que, a partir das respostas a um questionário de hábitos, classifique o usuário em uma das 7 categorias de status de peso (de `Insufficient_Weight` até `Obesity_Type_III`). O classificador serve como ferramenta de triagem em um app de Medicina do Estilo de Vida.

2. O que a IA faz no projeto?

A IA atua como um motor de classificação que aprende padrões de risco a partir de hábitos auto-relatados:

- Recebe os dados de estilo de vida do usuário (16 atributos categóricos e numéricos).

- Padroniza as variáveis (one-hot para categóricas, z-score para numéricas).
- Atravessa a rede neural MLP (entrada → camada oculta → saída).
- Retorna a probabilidade de o usuário pertencer a cada uma das 7 classes.
- Sinaliza o pilar mais crítico (alimentação, atividade física, etc.) para intervenção.

3. Dados

3.1 Dataset principal

ObesityDataSet_raw_and_data_synthetic.csv: <https://www.kaggle.com/datasets/jockeroika/life-style-data>

2.111 amostras × 17 colunas. Após remoção de duplicatas: 2.087 amostras. Não possui valores ausentes.

3.2 Dataset Suplementares

- Sleep Health and Lifestyle Dataset: <https://www.kaggle.com/datasets/uom190346a/sleep-health-and-lifestyle-dataset>
- Student Stress Monitoring Datasets: <https://www.kaggle.com/datasets/mdsultanulislamovi/student-stress-monitoring-datasets>
- Social Connections: <https://www.kaggle.com/datasets/willianoliveiragibin/social-connections>
- Illicit Drugs: <https://www.kaggle.com/datasets/willianoliveiragibin/illicit-drugs>


3.2 De onde vieram os dados?

Todos os dados foram retirados de datasets diferentes e públicos contidos no site Kaggel.

3.3 Mapeamento das variáveis aos pilares da Medicina do Estilo de Vida

Pilar	Variáveis	Significado
Nutrição	FAVC, FCVC, NCP, CAEC, CH2O, SCC	Frequência de calóricos, vegetais, nº de refeições, lanches, água, monitoramento
Atividade Física	FAF, TUE, MTRANS	Frequência de exercício, tempo de tela, meio de transporte
Substâncias de Risco	SMOKE, CALC	Fumo e consumo de álcool
Contexto	Gender, Age, Height, Weight, family_history_with_overweight	Demografia e histórico familiar
Alvo	NObeyesdad	7 classes de status de peso

3.5 Distribuição das classes



4. Modelo

Multilayer Perceptron (MLP) com 1 camada oculta totalmente conectada, implementada do zero em NumPy puro para fins didáticos.

4.1 Ferramenta utilizada

Python 3 + NumPy + pandas + matplotlib. A escolha por NumPy puro (em vez de sklearn ou TensorFlow) torna explícitos os mecanismos de forward, backward e atualização dos pesos — facilitando a apresentação. O código pode ser facilmente migrado para sklearn.MLPClassifier ou tf.keras.Sequential.

4.2 Estrutura básica do modelo

Arquitetura:

Entrada (31 features após one-hot) $\rightarrow$ Linear(31, 64) + ReLU $\rightarrow$ Linear(64, 7) + Softmax

Hiperparâmetros:

Item	Valor
Camada oculta	64 neurônios
Ativação oculta	ReLU
Camada de saída	Softmax (7 classes)
Função de perda	Cross-Entropy categórica
Otimizador	SGD com momentum ($\beta = 0.9$)
Taxa de aprendizado	0.05
Tamanho do mini-batch	64
Épocas	200
Inicialização	He ($\sqrt{2/n_{in}}$)
Split	70% treino / 10% validação / 20% teste (estratificado)


5. Código

O código se encontra dentro do repositório público com DE LINK:

https://github.com/GiantMazelliWasHere/IA_MLP_Sprint-3

6. Resultados

6.1 Curvas de aprendizado



6.2 Métricas globais


Métrica	Valor
Acurácia no teste	95.67%
Acurácia no treino (final)	100.00%
Acurácia na validação (final)	95.22%
Loss treino (final)	0.0026
Loss validação (final)	0.2114
Nº de features (após one-hot)	31
Nº de classes	7
Amostras treino / val / teste	1462 / 209 / 416

6.3 Métricas por classe

Classe	Precisão	Recall	F1	Suporte
Insufficient_Weight	0.930	1.000	0.964	53
Normal_Weight	0.877	0.893	0.885	56
Obesity_Type_I	1.000	0.957	0.978	70
Obesity_Type_II	0.967	1.000	0.983	59
Obesity_Type_III	1.000	1.000	1.000	65
Overweight_Level_I	0.940	0.855	0.895	55

Overweight_Level_II	0.966	0.983	0.974	58
---------------------	-------	-------	-------	----

6.4 Matriz de confusão



6.5 Discussão

O modelo atinge 95.67% de acurácia em 7 classes, com F1 acima de 0.96 em 5 das 7 categorias e F1 perfeito (1.000) em Obesity_Type_III. As confusões residuais ocorrem principalmente entre Normal_Weight e Overweight_Level_I — fronteira naturalmente fluida do ponto de vista clínico. As curvas de treino mostram convergência rápida (~20 épocas) sem overfitting severo: a loss de validação estabiliza em torno de 0.21 enquanto a acurácia de validação se mantém acima de 94%.

Os resultados confirmam empiricamente a tese central da Medicina do Estilo de Vida: hábitos alimentares, atividade física e consumo de substâncias são preditores robustos do status de peso, mesmo sem exames laboratoriais.